

Домашняя работа №1

Аналитическая оценка затрат CNN

S - сторона изображения

B - размер batch

Ввод: $B \cdot 3 \cdot S \cdot S$ $S: 16$

Принимем 1 MAC = 2 операции

Матрица:

Слой	Размер выноса	Параметры	Операции
Conv7, $3 \rightarrow 32$, stride 2	$32 \cdot \frac{S}{2} \cdot \frac{S}{2}$	4204	$2352 S^2$
MaxPool3, stride 2	$32 \cdot \frac{S}{4} \cdot \frac{S}{4}$	0	
Conv5 $32 \rightarrow 64$	$64 \cdot \frac{S}{4} \cdot \frac{S}{4}$	51200	$6400 S^2$
Conv3 $64 \rightarrow 128$	$128 \cdot \frac{S}{8} \cdot \frac{S}{8}$	73728	$2304 S^2$
Conv1 $128 \rightarrow 256$	$256 \cdot \frac{S}{8} \cdot \frac{S}{8}$	32768	$1024 S^2$
Conv3 $256 \rightarrow 256$	$256 \cdot \frac{S}{16} \cdot \frac{S}{16}$	589824	$4608 S^2$
Conv1 $256 \rightarrow 512$	$512 \cdot \frac{S}{16} \cdot \frac{S}{16}$	131072	$1024 S^2$
Global Avg Pool	512	0	
Linear 512-256	256	131328	262144
Linear 256-100	100	25700	51200

Число операций свёртки равно произведению выходов элементов, умноженному на мощность выхода элемента:

$$F_{conv} = 2 B H_{out} W_{out} C_{out} C_{in} k^2$$

для первой свёртки:

$$F_1 = 2 B \left(\frac{S}{2}\right)^2 \cdot 32 \cdot 3 \cdot 3^2 = 2352 B S^2$$

для Linear

$$F_{linear} = 2 B d_{in} d_{out}$$

Сумма:

$$F_{MAC} = B [(2352 + 6400 + 2304 + 1024 + 4608 + 1024) S^2 + 262144 + 51200]$$

$$F_{MAC} = B (17712 S^2 + 313344)$$

ReLU:

$$F_{ReLU} = (8 + 4 + 2 + 4 + 1 + 2) B S^2 + 256 B = 21 B S^2 + 256 B$$

MaxPool:

$$F_{pool} = 8 \cdot 2 B S^2 = 16 B S^2$$

GAP:

$$F_{GAP} = 512 B \cdot n = 2 B S^2$$

$$F_{bias} = (256 + 100) B = 356 B$$

$$F(S, B) = B (17751 S^2 + 313956)$$

Память

Общее число параметров

$$P = 4704 + 51200 + 83228 + 32768 + 589824 + 131072 + 25200 = 1046324$$

FP32 занимает 4 байта

$$M_{\text{weights}} = 4P = 4161296 \text{ байт}$$

Обозначу $X = BS^2$, размеры активаций

$3X, 8X, 2X, 4X, 2X, 4X, X, 2X$

Макс сумма акт-ий получается на MaxPool: $8X + 2X = 10X$

$$M = 4(P + 3X + 10X)$$

$$M(S, B) = 4161296 + 52BS^2 \text{ байт}$$

Данная оценка может занижать ист. память, т.к. не учитывает разные групповые моменты

Добавим операции

Свёртки

$37X$

ReLU

$42X$

MaxPool

$10X$

GAP

$2X + 512B$

2 Linear

$1124B$

ReLU после Linear

$512B$

$$Q = 4[P + (37 + 42 + 10 + 2)X + (512 + 1124 + 512)B]$$

$$Q(S, B) = 4[1040324 + B(91S^2 + 2148)] \text{ байт}$$

Брежневская приближ. перекрытие вычислений и передачи данных. Время оцениваю как постоянные накладные расходы + максимум вычислительной и памяти занятой частей

$$T(S, B) = \tau + \max(\alpha F(S, B), \beta Q(S, B))$$

τ - секунды

α - секунды на операцию

β - секунды на байт

поиск минимума по 63 осм. точкам

$$\min_{\tau, \alpha, \beta \geq 0} \sum_{i \in \mathcal{B}_{32}} \left(\frac{T(S_i, B_i) - t_i}{t_i} \right)^2$$

по измерениям Tesla P4

$$\tau = 3.643056 \cdot 10^{-4} \quad \alpha = 3.100139 \cdot 10^{-13} \quad \beta = 1.289107 \cdot 10^{-11}$$

даширование:

τ - launch-bound

βQ - memory-bound

αF - compute-bound

Для энергии такая формула:

$$E(S, B) = p_0 T(S, B) + \varepsilon_F F(S, B) + \varepsilon_Q Q(S, B)$$

$$p_0 = 66.078929 \quad \varepsilon_F = 1.579116 \cdot 10^{-12} \quad \varepsilon_Q = 0$$

Куревский характеризует преграда не осм., что память не расходуется энергией, т.е. её вклад кельва незначителен от остальных в этой модели

Измеренная энергия - интеграл мощности NVML

За блок проходов глупейшим образом не менее
3 секунды, глупейшим на их количество N

$$E_{\text{mean}} \approx \frac{1}{N} \sum_j \frac{p_j + p_{j+1}}{2} (t_{j+1} - t_j)$$

$$\text{для } S=224, B=1$$

$$F = 12951 \cdot 224^2 + 313956 = 290988132 \text{ операций}$$

$$M = 4161296 = 52 \cdot 224^2 = 6790448 \text{ байт}$$

$$Q = 4 [1040324 + 91 \cdot 224^2 + 2148] = 22433952 \text{ байт}$$

$$T \approx 0.364306 + \max(0.276219, 0.282949) = 0.653055 \text{ мс}$$

$$E \approx 66.028729 - 0.000$$

~~Ближайшее время вычисления на 67 год. комбинация
размеров, не угадан~~